Добрый вечер ребята

Сегодня я хочу вспомнить все основные аспекты, которые я прошел ранее, а заодно пройдусь по новой теории, на которую раньше не обращал внимание.
Опустим Линейную регрессию, ей мы и так очень много занимались. Кроме линейной, существует еще логистическая регрессия, и сегодня мы изучим именно ее.

Для начала загрузим все библиотеки, которые будем использовать

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os
```

```
#Прочитаем датасет, который я нашел в недрах интернета
data=pd.read_csv('data.csv')
#Давайте удалим пустой столбец, раз уж он нам не нужен
data.drop(['Unnamed: 32','id'], axis=1, inplace=True) #inplace=True позволяет изменить оригинал датасета, если бы мы не написали, то изменялась бы копия. Поэтому с этим параметром можно не писать data=data.drop...
data
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactnes
0	M	17.99	10.38	122.80	1001.0	0.11840	0.27760
1	M	20.57	17.77	132.90	1326.0	0.08474	0.07864
2	M	19.69	21.25	130.00	1203.0	0.10960	0.15990
3	M	11.42	20.38	77.58	386.1	0.14250	0.28390
4	M	20.29	14.34	135.10	1297.0	0.10030	0.13280
...	...	...	...	...	...	...	...
564	M	21.56	22.39	142.00	1479.0	0.11100	0.11590
565	M	20.13	28.25	131.20	1261.0	0.09780	0.10340
566	M	16.60	28.08	108.30	858.1	0.08455	0.10230
567	M	20.60	29.33	140.10	1265.0	0.11780	0.27700
568	B	7.76	24.54	47.92	181.0	0.05263	0.04362

569 rows × 31 columns

```
# Напишем небольшой код чтобы быстро скопировать названия столбцов в нужном нам формате
i=0
for name in data.columns:
    print(f"* {name} - ")
    i+=1
```

```
* diagnosis -
* radius_mean -
* texture_mean -
* perimeter_mean -
* area_mean -
* smoothness_mean -
* compactness_mean -
* concavity_mean -
* concave points_mean -
* symmetry_mean -
* fractal_dimension_mean -
* radius_se -
* texture_se -
* perimeter_se -
* area_se -
* smoothness_se -
* compactness_se -
* concavity_se -
* concave points_se -
* symmetry_se -
* fractal_dimension_se -
* radius_worst -
* texture_worst -
* perimeter_worst -
* area_worst -
* smoothness_worst -
* compactness_worst -
* concavity_worst -
* concave points_worst -
* symmetry_worst -
* fractal_dimension_worst -
```

Давайте рассмотрим эту таблицу и вообще поймем, каике столбцы что обозначают.

- id - id клиента
- diagnosis - Диагноз (M = злокачественный, B = доброкачественный)
- radius_mean - радиус (среднее значение расстояний от центра до точек по периметру)
- texture_mean - текстура (стандартное отклонение значений шкалы серого)
- perimeter_mean - периметр
- area_mean - область
- smoothness_mean - плавность (локальное изменение длины радиуса)
- compactness_mean - компактность (периметр^2 / площадь - 1,0)
- concavity_mean - вогнутость (выраженность вогнутых участков контура)
- concave points_mean - точки вогнутости (количество вогнутых участков контура)
- symmetry_mean - симметрия
- fractal_dimension_mean - фрактальное измерение ("приближение береговой линии" - 1)
- radius_se - стандартная ошибка для среднего значения расстояний от центра до точек по периметру
- texture_se - стандартная ошибка для стандартного отклонения значений шкалы серого
- perimeter_se - стандартная ошибка для периметра
- area_se - *по аналогии*

- smoothness_se -
- compactness_se -
- concavity_se -
- concave points_se -
- symmetry_se -
- fractal_dimension_se -
- radius_worst - "наихудшее" или наибольшее среднее значение для среднего расстояния от центра до точек по периметру
- texture_worst - "наихудшее" или наибольшее среднее значение для стандартного отклонения значений по шкале серого
- perimeter_worst - *по аналогии*
- area_worst -
- smoothness_worst - "наихудшее" или наибольшее среднее значение для локального изменения длин радиусов
- compactness_worst - *по аналогии*
- concavity_worst -
- concave points_worst -
- symmetry_worst -
- fractal_dimension_worst -

```
print(data.diagnosis)
data.diagnosis = [1 if each == "M" else 0 for each in data.diagnosis]
data.diagnosis
```

```
0      M
1      M
2      M
3      M
4      M
      ..
564    M
565    M
566    M
567    M
568    B
Name: diagnosis, Length: 569, dtype: object
```

```
0      1
1      1
2      1
3      1
4      1
      ..
564    1
565    1
566    1
```

```
567    1
568    0
Name: diagnosis, Length: 569, dtype: int64
```

```
#Теперь давйте разделим наши данные для более удобной обработки
print(data.diagnosis.values) #позволяет из датафрейма перейти в список
y=data.diagnosis.values
#y=data.diagnosis
x_data=data.drop(['diagnosis'], axis=1)
```

```
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 0 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1
 0 1 1 1 1 1 1 1 1 0 1 0 0 0 0 0 1 1 0 1 1 0 0 0 0 1 0 1 1 0 0 0 0 1 0 1 1
 0 1 0 1 1 0 0 0 1 1 0 1 1 1 0 0 0 1 0 0 1 1 0 0 0 1 1 0 0 0 0 1 0 0 1 0 0
 0 0 0 0 0 0 1 1 1 0 1 1 0 0 0 1 1 0 1 0 1 1 0 1 1 0 0 1 0 0 1 0 0 0 0 1 0
 0 0 0 0 0 0 0 0 1 0 0 0 0 1 1 0 1 0 0 1 1 0 0 1 1 0 0 0 0 1 0 0 1 1 1 0 1
 0 1 0 0 0 1 0 0 1 1 0 1 1 1 1 0 1 1 1 0 1 0 1 0 0 1 0 1 1 1 1 0 0 1 1 0 0
 0 1 0 0 0 0 0 1 1 0 0 1 0 0 1 1 0 1 0 0 0 0 1 0 0 0 0 0 1 0 1 1 1 1 1 1 1
 1 1 1 1 1 1 1 0 0 0 0 0 0 1 0 1 0 0 1 0 0 1 0 1 1 0 0 0 0 0 0 0 0 0 0 0 0
 0 1 0 0 1 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 1 0 0 0 1 0 1 0 0 0 0 1 1 1 0 0
 0 0 1 0 1 0 1 0 0 0 1 0 0 0 0 0 0 0 1 1 1 0 0 0 0 0 0 0 0 0 0 1 1 0 1 1
 1 0 1 1 0 0 0 0 0 1 0 0 0 0 0 1 0 0 0 1 0 0 1 1 0 0 0 0 0 0 1 0 0 0 0 0 0
 0 1 0 0 0 0 0 1 0 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 1 0 1 1 0 1 0 0 0 0 0 1 0 0
 1 0 1 0 0 1 0 1 0 0 0 0 0 0 0 1 1 0 0 0 0 0 0 1 0 0 0 0 0 0 0 0 0 0 1 0
 0 0 0 0 0 0 1 0 1 0 0 1 0 0 0 0 0 0 1 1 0 1 0 1 0 0 0 0 0 1 0 0 1 0 1 0 1 1
 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 1 0 1 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
 0 0 0 0 0 0 0 1 1 1 1 1 1 0]
```

Min-Max Нормализация

Существует метод, который изменяет масштаб значений, чтобы они находились в диапазоне от 0 до 1. Кроме того, данные в конечном итоге имеют меньшие стандартные отклонения, что может подавить эффект выбросов.
Формула Min-Man Нормализации выглядит следующим образом:

$$x_{i,norm} = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

x_i — i — й *непреобразованный элемент* $x_{\min}$ — *наименьший элемент* $x_{\max}$ — *наибольший элемент*

```
#функции np.min и np.max вовращают мин и макс значения датафрейма
np.min(x_data, axis=0)
```

```
radius_mean                6.981000
texture_mean               9.710000
perimeter_mean            43.790000
area_mean                143.500000
smoothness_mean            0.052630
compactness_mean           0.019380
concavity_mean             0.000000
concave points_mean        0.000000
symmetry_mean              0.106000
fractal_dimension_mean     0.049960
```

```
radius_se                   0.111500
texture_se                  0.360200
perimeter_se                0.757000
area_se                     6.802000
smoothness_se               0.001713
compactness_se              0.002252
concavity_se                0.000000
concave points_se           0.000000
symmetry_se                 0.007882
fractal_dimension_se        0.000895
radius_worst                7.930000
texture_worst              12.020000
perimeter_worst            50.410000
area_worst                185.200000
smoothness_worst            0.071170
compactness_worst           0.027290
concavity_worst             0.000000
concave points_worst        0.000000
symmetry_worst              0.156500
fractal_dimension_worst     0.055040
dtype: float64
```

```
#Нормализация
x=((x_data-np.min(x_data, axis=0))/(np.max(x_data,axis=0)-np.min(x_data, axis=0))).values
x
```

```
array([[0.52103744, 0.0226581 , 0.54598853, ..., 0.91202749, 0.59846245,
        0.41886396],
       [0.64314449, 0.27257355, 0.61578329, ..., 0.63917526, 0.23358959,
        0.22287813],
       [0.60149557, 0.3902604 , 0.59574321, ..., 0.83505155, 0.40370589,
        0.21343303],
       ...,
       [0.45525108, 0.62123774, 0.44578813, ..., 0.48728522, 0.12872068,
        0.1519087 ],
       [0.64456434, 0.66351031, 0.66553797, ..., 0.91065292, 0.49714173,
        0.45231536],
       [0.03686876, 0.50152181, 0.02853984, ..., 0.        , 0.25744136,
        0.10068215]])
```

```
from sklearn.model_selection import train_test_split
x_train,x_test,y_train,y_test= train_test_split(x,y,test_size=0.15, random_state=42)
x_train=x_train.T
x_test=x_test.T
y_train=y_train.T
y_test=y_test.T
print('Размеры разделенных массивов')
print(f"x_train: {x_train.shape}\nx_test: {x_test.shape}\ny_train: {y_train.shape}\ny_test:
{y_test.shape}\n")
```

```
Размеры разделенных массивов
x_train: (30, 483)
```

```
x_test: (30, 86)
y_train: (483,)
y_test:(86,)
```

```
# В дальнейшем понадобится
def initialize_weights_and_bias(dimension):
    w = np.full((dimension,1),0.01)
    b = 0.0
    return w, b

a,b=initialize_weights_and_bias(4096)
print(a.shape)
print(a)
```

```
(4096, 1)
[[0.01]
 [0.01]
 [0.01]
 ...
 [0.01]
 [0.01]
 [0.01]]
```

```
#%% Сигмоида
# Нужна для решения логистического уравнения, приводит к сглаживанию некоторых значений, и для оценки вероятности событий
#z = np.dot(w.T,x_train)+b
def sigmoid(z):
    y_head = 1/(1+np.exp(-z))
    return y_head
#y_head = sigmoid(5)
```

Оценка работы машинного обучения

```
Оценить — означает указать количественно, хорошо или плохо сеть решает поставленные ей задачи. Для этого строится функция оценки. Она, как правило, явно зависит от выходных сигналов сети и неявно (через функционирование) — от всех её параметров. Простейший и самый распространённый пример оценки — сумма квадратов расстояний от выходных сигналов сети до их требуемых значений:
```

$$H = \frac{1}{2} \cdot \sum_{r} (Z(r) - Z^*(r))^2$$

Метод наименьших квадратов далеко не всегда является лучшим выбором оценки. Тщательное конструирование функции оценки позволяет на порядок повысить эффективность обучения сети, а также получать дополнительную информацию — «уровень уверенности» сети в даваемом ответе. Именно поэтому были придуманы другие способы оценки. Мы же воспользуемся градиентным спуском, однако коэффициенты для спуска будут меняться после каждого шага, поэтому вы в любом случае найдем минимум. Единственной проблемой является нахождение ошибочного минимума, который называется просто **локальным** минимумом.

Так как у нас будет двоичная классификация (злокачественная или доброкачественная опухоль), то нам нужно будет получить значения в форме вероятностей.
Это нужно нам для того, чтобы применить функцию активации. К примеру, если вероятность злокачественной будет >50%, то мы скажем Да, а если <50%, то скажем Нет.

Но как это реализовать в масштабах машинного обучения? Нам же нужно, чтобы машина училась на своих же ошибках.
Для этого мы будет брать Сигмоиду от наших данных.

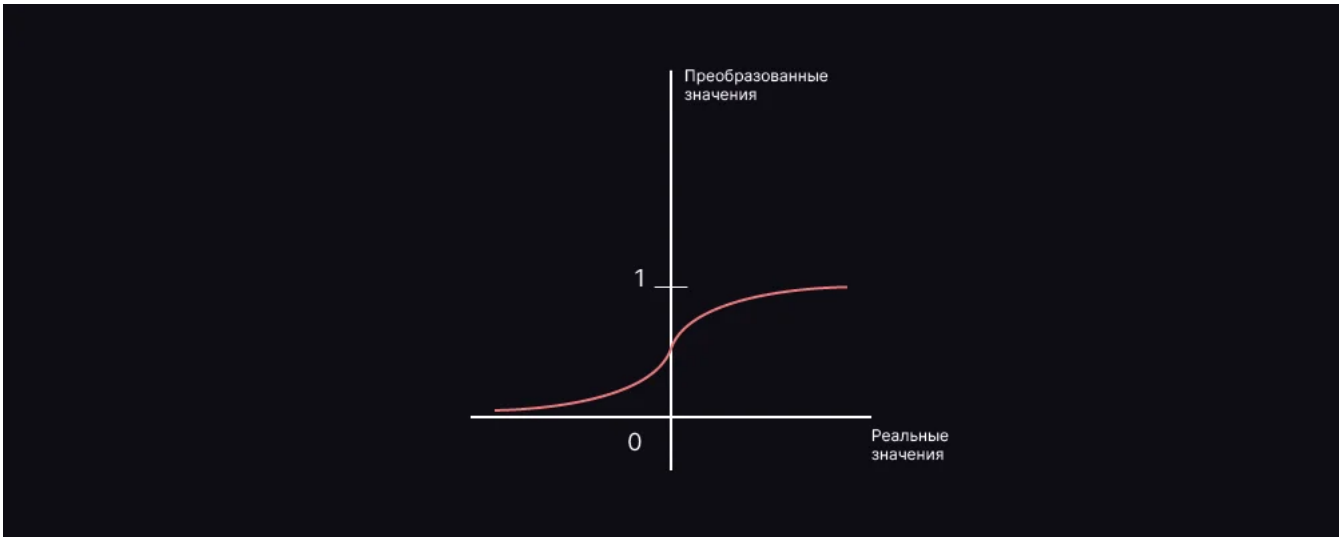

Ну и также в случае бинарной классификации(Собака или кошка = 0 или 1) функция Потерь будет иметь вид

$$CE = -\left(y \log(p) + (1-y) \log(1-p)\right)$$

```
#forward and backward propagation
def forward_backward_propagation(w,b,x_train,y_train):
    #forward pass

    z=np.dot(w.T,x_train)+b #Перемножим
    # print(x_train.shape)
    # print(w.T.shape)
    # print(z.shape)
    y_head=sigmoid(z)
    loss = -y_train*np.log(y_head)-(1-y_train)*np.log(1-y_head) #функция потерь
    cost = (np.sum(loss))/x_train.shape[1]      # x_train.shape[1]  is for scaling
    # backward propagation
    derivative_weight = (np.dot(x_train,((y_head-y_train).T)))/x_train.shape[1] # x_train.shape[1]
is for scaling
    derivative_bias = np.sum(y_head-y_train)/x_train.shape[1]                 # x_train.shape[1]
is for scaling
    gradients = {"derivative_weight": derivative_weight,"derivative_bias": derivative_bias}
    return cost,gradients
```

```
#%%# Updating(learning) parameters
def update(w, b, x_train, y_train, learning_rate,number_of_iterarion):
    cost_list = []
    cost_list2 = []
    index = []
    # updating(learning) parameters is number_of_iterarion times
    for i in range(number_of_iterarion):
        # make forward and backward propagation and find cost and gradients
        cost,gradients = forward_backward_propagation(w,b,x_train,y_train)
        cost_list.append(cost)
        # lets update
        w = w - learning_rate * gradients["derivative_weight"]
        b = b - learning_rate * gradients["derivative_bias"]
        if i % 10 == 0:
            cost_list2.append(cost)
```

```
            index.append(i)
            print ("Cost after iteration %i: %f" %(i, cost))
    # we update(learn) parameters weights and bias
    parameters = {"weight": w,"bias": b}
    plt.plot(index,cost_list2)
    plt.xticks(index,rotation='vertical')
    plt.xlabel("Number of Iterarion")
    plt.ylabel("Cost")
    plt.show()
    return parameters, gradients, cost_list
```

```
#%%  # prediction
def predict(w,b,x_test):
    # x_test is a input for forward propagation
    z = sigmoid(np.dot(w.T,x_test)+b)
    Y_prediction = np.zeros((1,x_test.shape[1]))
    # if z is bigger than 0.5, our prediction is sign one (y_head=1),
    # if z is smaller than 0.5, our prediction is sign zero (y_head=0),
    for i in range(z.shape[1]):
        if z[0,i]<= 0.5:
            Y_prediction[0,i] = 0
        else:
            Y_prediction[0,i] = 1

    return Y_prediction
# predict(parameters["weight"],parameters["bias"],x_test)
```

```
# %%
def logistic_regression(x_train, y_train, x_test, y_test, learning_rate ,  num_iterations):
    # initialize
    dimension =  x_train.shape[0]  # that is 4096
    w,b = initialize_weights_and_bias(dimension)
    # do not change learning rate
    parameters, gradients, cost_list = update(w, b, x_train, y_train, learning_rate,num_iterations)

    y_prediction_test = predict(parameters["weight"],parameters["bias"],x_test)
    y_prediction_train = predict(parameters["weight"],parameters["bias"],x_train)

    # Print train/test Errors
    print("train accuracy: {} %".format(100 - np.mean(np.abs(y_prediction_train - y_train)) * 100))
    print("test accuracy: {} %".format(100 - np.mean(np.abs(y_prediction_test - y_test)) * 100))

logistic_regression(x_train, y_train, x_test, y_test,learning_rate = 1, num_iterations = 100)
```

```
Cost after iteration 0: 0.692836
Cost after iteration 10: 0.498576
Cost after iteration 20: 0.404996
Cost after iteration 30: 0.350059
Cost after iteration 40: 0.313747
Cost after iteration 50: 0.287767
Cost after iteration 60: 0.268114
Cost after iteration 70: 0.252627
Cost after iteration 80: 0.240036
Cost after iteration 90: 0.229543
```

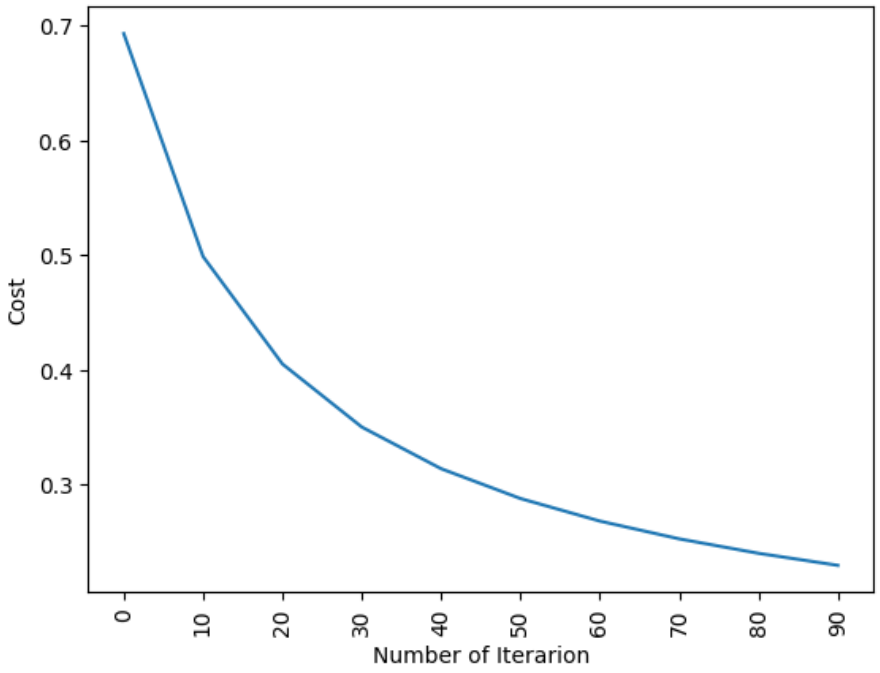


```
train accuracy: 94.40993788819875 %
test accuracy: 94.18604651162791 %
```

А теперь сделаем то же самое, но с использованием встроенной функции от sklearn)

```
# sklearn
from sklearn import linear_model
logreg = linear_model.LogisticRegression(random_state = 51,max_iter= 150)
print(f"test accuracy: {logreg.fit(x_train.T, y_train.T).score(x_test.T, y_test.T)} ")
print(f"train accuracy: {logreg.fit(x_train.T, y_train.T).score(x_train.T, y_train.T)} ")
logreg.fit(x_train.T, y_train.T)
```

```
test accuracy: 0.9767441860465116
train accuracy: 0.968944099378882
```

```
LogisticRegression(max_iter=150, random_state=51)
```

**In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.
On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.**

```
#Давайте проверим работоспособность машины на каком-нибудь примере.
def predicting(test,n):
    print('\n--------------------------------------')
    print(f"Настоящий результат:{y[n]}")
    Prediction=logreg.predict(test)
    print(f'Машинный результат:{Prediction}\n----------------------\n')
    call='не '
    call2='доброкачественная'
    if Prediction[0]:
        call=''
        call2='злокачественная'
    print(f"Поздравляем вас, вы {call}больны. Ваша опухоль {call2}!")
```

```
n=500
for n in range(497,500):
```

```
    test=[x[n]]
    predicting(test,n)
```

```
-------------------------------------
Настоящий результат:0
Машинный результат:[0]
----------------------

Поздравляем вас, вы не больны. Ваша опухоль доброкачественная!

-------------------------------------
Настоящий результат:1
Машинный результат:[1]
----------------------

Поздравляем вас, вы больны. Ваша опухоль злокачественная!

-------------------------------------
Настоящий результат:1
Машинный результат:[1]
----------------------

Поздравляем вас, вы больны. Ваша опухоль злокачественная!
```

Недостатки

1. Машина может и переобучиться, за этим также нужно следить
2. Машина воспринимает данные только в нормализованном виде, а значит, нужно постоянно хранить значения для тренировки (train), потому что иначе при добавлении